

Fluxo de Custo Mínimo em Redes Hídricas Urbanas

Uma Abordagem via Successive Shortest Paths

Arthur Augusto Campos

Prof. Dr. Marcelo Marotta

Universidade de Brasília (UnB)
Programa de Pós-Graduação em Informática (PPGI)

16 de junho de 2026

Sumário

- 1 Introdução e Motivação
- 2 Formulação e Algoritmo
- 3 Execução na Instância
- 4 Resultados da Otimização
- 5 Conclusão e Fechamento

Roteiro

● Parte 1: Caso de Estudo

- Alocação de Água no DF
- Trabalhos de Referência
- A Instância Hídrica

● Parte 2: Formulação e Algoritmo

- Fluxo de Custo Mínimo (MCF)
- Grafo Residual e Otimalidade
- Algoritmo SSP e Complexidade

● Parte 3: Demonstração e Resultados

- Execução Iterativa SSP
- Resultados da Alocação
- Limitações e Sensibilidade

● Parte 4: Conexão Estocástica

- Pontes de Schrödinger
- O Poder da Incerteza
- Conclusão

O Problema de Alocação de Água

Contexto Real

Como distribuir água potável de forma eficiente a partir de Estações de Tratamento de Água (ETAs) para as Regiões Administrativas (RAs) do Distrito Federal?

- **Desafio:** Equilibrar a capacidade instalada de produção (supply) e as demandas locais das RAs (demand).
- **Custos:** Perdas físicas, infraestrutura e, principalmente, custo de bombeamento (energia elétrica).
- **Pergunta Central:**

Pergunta

Dado o grafo de adutoras, qual é a alocação de fluxo que atende a todas as demandas minimizando o custo total de transporte?

Trabalhos de Referência

Nossa modelagem é inspirada em estudos de transporte ótimo em redes hídricas:

- **Mascherpa et al. (2023)**: Uso de transporte ótimo regularizado para modelar o fluxo de água e contaminantes em redes de distribuição.
- **Mascherpa et al. (2026)**: Estimação de contaminação sob incerteza e observabilidade da rede.

Abordagem Determinística e Escopo

- **Modelo Determinístico (SSP):** Foco no algoritmo *Successive Shortest Path* para resolver o fluxo de custo mínimo sem incertezas na demanda.
- **Implementação do Zero:** Desenvolvimento puro do resolvedor, sem depender de pacotes ou solvers externos prontos.
- **Complexidade Estocástica:** A inserção de incertezas nas demandas tornaria o problema estocástico e altamente complexo (frequentemente NP-difícil).
- **Fundamentação Básica:** A modelagem determinística é etapa inicial obrigatória antes de qualquer extensão estocástica.

Do Modelo à Aplicação: O Caso de Estudo

Para validar o resolvidor desenvolvido, aplicamos a modelagem a um cenário real e crítico:

Caso de Estudo: Alocação Hídrica no Distrito Federal

A infraestrutura de distribuição de água potável da CAESB pode ser descrita como uma rede de fluxo, onde:


- **Estações de Tratamento (ETAs)** agem como fontes de suprimento de água.
- **Regiões Administrativas (RAs)** agem como sumidouros (demandas locais).
- **Adutoras** representam arcos de tráfego com custos de bombeamento específicos.

A Instância Hídrica do Distrito Federal

- **Topologia:** Grafo bipartido com 7 ETAs (fontes) e 7 RAs (sumidouros), interconectados por 26 adutoras.
- **Dados:** Baseados em estatísticas reais da CAESB e ADASA.

Nó	Tipo	Balanço Nodal (l/s)
ETA Rio Descoberto	Fonte	+4450.00
ETA Brasília	Fonte	+1200.00
ETA Lago Norte	Fonte	+700.00
ETA Sobradinho	Fonte	+570.00
ETA Gama	Fonte	+320.00
ETA Paranoá	Fonte	+300.00
ETA Planaltina	Fonte	+60.00
Plano Piloto	Sumidouro	-1763.40
Sobradinho	Sumidouro	-1101.09
Guará	Sumidouro	-1067.97
Taguatinga	Sumidouro	-1051.42
Planaltina	Sumidouro	-927.23
Samambaia	Sumidouro	-852.72
Ceilândia	Sumidouro	-836.17

Topologia da Rede Hídrica do DF



- **Objetivo:** Encontrar o plano de fluxos ótimos x_{ij}^* para cada adutora.
- **Visualização dos Fluxos:** Arestas mais espessas representam fluxos maiores, enquanto arestas ociosas tornam-se inativas.



Componentes do Modelo de Otimização

Correspondência com a Instância Hídrica

- x_{ij} : Vazão (fluxo) de água alocada na adutora (i, j) (em l/s).
 - b_i : Balanço do nó i . Se $b_i > 0$, é uma ETA (produção). Se $b_i < 0$, é uma RA (demanda). Se $b_i = 0$, é um nó de passagem.
 - u_{ij} : Capacidade máxima física de vazão na adutora (i, j) (em l/s).
 - c_{ij} : Distância em linha reta em km (proxy para o custo de bombeamento).
-
- A conservação de fluxo assegura que nenhuma água “some” ou é adicionada em trânsito.
 - A restrição de capacidade limita o fluxo ao máximo suportado pela tubulação física.

Formulação Matemática do Fluxo de Custo Mínimo

O problema de alocação hídrica é modelado como um problema de **Fluxo de Custo Mínimo (MCF)**:

$$\begin{aligned} \min \quad & \sum_{(i,j) \in A} c_{ij} x_{ij} \\ \text{sujeito a:} \quad & \sum_{\{j: (i,j) \in A\}} x_{ij} - \sum_{\{j: (j,i) \in A\}} x_{ji} = b_i \quad \forall i \in V \\ & 0 \leq x_{ij} \leq u_{ij} \quad \forall (i,j) \in A \end{aligned}$$

O Pulo do Gato: O Grafo Residual

Para resolver o MCF de forma eficiente, a ideia central é trabalhar com o **grafo residual**: uma representação dinâmica que permite ao algoritmo corrigir decisões de fluxo anteriores.

- **Arcos forward**: Representam a capacidade ainda disponível para enviar mais fluxo.
- **Arcos backward**: Permitem “devolver” fluxo já enviado, revertendo decisões subótimas.
- **Consequência**: O algoritmo não fica preso em soluções parciais ruins — ele sempre pode se autocorrigir.

É essa estrutura que transforma uma heurística gulosa em um algoritmo exato.

Estrutura do Grafo Residual

O grafo residual G_x permite que o algoritmo retroceda decisões anteriores redirecionando fluxo pelas arestas reversas.



Condições de Otimalidade

A teoria de otimização em redes fornece condições necessárias e suficientes para certificar que uma solução é ótima:

- **Potenciais de nó** (π_i): Variáveis duais associadas à conservação de fluxo em cada nó da rede.
- **Custos reduzidos** ($\bar{c}_{ij} = c_{ij} - \pi_i + \pi_j$): Ajustam os custos originais das arestas usando os potenciais, permitindo o uso de Dijkstra.
- **Teorema de Otimalidade [1]**: Uma solução viável é ótima se e somente se todos os custos reduzidos no grafo residual são não-negativos ($\bar{c}_{ij} \geq 0$).

Os potenciais e custos reduzidos são a peça-chave que garante a corretude do SSP.

Pseudocódigo do Algoritmo Successive Shortest Path

O SSP resolve o MCF enviando fluxo de forma incremental ao longo de caminhos mínimos.

Algoritmo 1: Successive Shortest Path

Entrada: Grafo $G = (V, A)$, balanços b , capacidades u , custos c

Saída : Fluxo ótimo x

```
1 Inicializa  $x \leftarrow 0$  (fluxo nulo);
2 Calcula potenciais iniciais  $\pi$  via Bellman-Ford;
3 while existe nó  $s$  com excesso  $e(s) > 0$  do
4     Escolhe nó  $t$  com déficit  $e(t) < 0$ ;
5     Encontra caminho  $P$  de custo mínimo reduzido  $\bar{c}$  de  $s$  a  $t$  em  $G_x$  (Dijkstra com  $\bar{c}_{ij} \geq 0$ );
6     Atualiza potenciais  $\pi_i \leftarrow \pi_i - d(i)$  para todo  $i \in V$  (onde  $d(i)$  é a distância de  $s$  a  $i$ );
7      $\delta \leftarrow \min(e(s), -e(t), \min_{(i,j) \in P} r_{ij})$ ;
8     Aumenta  $\delta$  unidades de fluxo ao longo de  $P$  no grafo  $x$ ;
9     Atualiza excessos:  $e(s) \leftarrow e(s) - \delta$  e  $e(t) \leftarrow e(t) + \delta$ ;
10 end
11 return  $x$ ;
```

Análise de Complexidade

- **Inicialização (Bellman-Ford):** Executado uma única vez para calcular os potenciais iniciais π . Custo: $O(VE)$.
- **Custo por Iteração (Dijkstra em Lista):** Busca por caminho mínimo com busca linear simples. Custo: $O(V^2)$ por iteração [2].
- **Número de Iterações:** No máximo U iterações, onde $U = \sum_{b_i > 0} b_i$ é a soma dos excessos das fontes.
- **Complexidade Total:** $O(VE + U \cdot V^2)$.



Demonstração ao Vivo


Executando o resolvidor em terminal:

```
python ssp_main.py
```

Interface interativa do algoritmo SSP

SSP — Iteração 1

Aumento Local: ETA Sobradinho → Sobradinho **Custo:** 5.56 | **Fluxo:** 570.00 l/s
Resultado: Demanda suprida localmente (2.8 km).




SSP — Iteração 2

Aumento Local: ETA Rio Descoberto → Ceilândia

Custo: 0.00 |


Fluxo: 836.17 l/s

Resultado: Atendimento à maior demanda via adutora principal.



SSP — Iteração 3


Aumento Local: ETA Brasília → Guará **Custo:** 0.00 | **Fluxo:** 1067.97 l/s
Resultado: Atendimento direto (11.1 km).



SSP — Exemplo de Caminho Residual

Caminho Aumentante Residual: ETA Paranoá → Sobradinho → ETA Sobradinho → Planaltina

Custo: 0.00 | **Fluxo:** 167.23 l/s *Nota:* Utiliza o arco reverso Sobradinho → ETA Sobradinho (reversão).



Síntese da Solução

Origem	Destino	Fluxo (l/s)	Uti. (%)
Descoberto	Ceilândia	836.17	13.9%
Descoberto	Guará	1067.97	53.4%
Descoberto	Plano Piloto	961.72	48.1%
Descoberto	Samambaia	532.72	8.9%
Descoberto	Taguatinga	1051.42	17.5%
Brasília	Plano Piloto	801.68	66.8%
Brasília	Sobradinho	398.32	39.8%
Gama	Samambaia	320.00	100.0%
Lago Norte	Planaltina	700.00	70.0%
Paranoá	Sobradinho	300.00	100.0%
Planaltina	Planaltina	60.00	6.0%
Sobradinho	Planaltina	167.23	16.7%
Sobradinho	Sobradinho	402.77	67.1%

- **Custo Total:**
129.482 km.l/s
- **Arcos Saturados (100%):**
 - Gama → Samambaia
 - Paranoá → Sobradinho
- **Arcos Ociosos:**
 - 13 adutoras adicionais operam com fluxo zero.

Resultados — Visualização Geográfica




Figure: Visualização da Solução Ótima SSP (Adutoras Ativas em Laranja)

Nota: Consulte o mapa georreferenciado interativo no arquivo mapa_interativo.html para visualização sobre o relevo e Lago Paranoá.

Limitações e Análise de Sensibilidade

Embora o modelo SSP forneça a melhor alocação sob custos lineares determinísticos, apresenta limitações estruturais:

- **Custo Linear vs. Custo Não-Linear:** Modelamos o custo de transporte linearmente com a distância. Em redes hidráulicas reais, a perda de carga segue modelos não-lineares (**Hazen-Williams** ou **Darcy-Weisbach**).
- **Pressão Nodal:** Ignoramos limites mínimos de pressão requeridos para o funcionamento dos ramais de distribuição.
- **Altimetria:** O relevo do Distrito Federal (topologia 3D) impõe custos adicionais de elevação hidrostática (bombeamento morro acima).
- **Incerteza:** As demandas são tomadas como estáticas, mas variam dinamicamente ao longo do dia.

Conexão com Schrödinger: O Salto Estocástico

- **O Salto Estocástico:** Se as demandas das RAs fossem modeladas como distribuições de probabilidade (ex: incerteza climática ou demográfica rápida), o problema determinístico clássico torna-se um **Problema de Ponte de Schrödinger (SBP) com informação parcial**.
- **Algoritmo e Massa Variável [5]:**
 - O espalhamento de contaminantes ou flutuações de água é modelado como uma cadeia de Markov sobre o grafo, onde os estados são os trechos de tubulação.
 - Um algoritmo proximal entrópico baseado em iterações do tipo Sinkhorn é empregado para resolver instâncias onde a massa total não é constante e as margens inicial/final são apenas parcialmente observadas.

O Poder da Incerteza: Regularização e Eficiência

Paradoxo: Adicionar Ruído Melhora o Algoritmo

Em problemas de transporte ótimo, a introdução controlada de incerteza traz ganhos algorítmicos concretos.

- **Cuturi (2013) — Regularização Entrópica [3]:** Adicionar entropia ao objetivo transforma o problema em operações matriciais simples (Sinkhorn), reduzindo drasticamente o custo computacional.
- **Pontes de Schrödinger:** Ao modelar o transporte como processo estocástico, ganha-se estabilidade numérica e capacidade de tratar dados ruidosos ou parcialmente observados.
- **Visão Unificada:** Determinístico $\rightarrow$ Regularizado $\rightarrow$ Estocástico forma um espectro onde cada nível de incerteza adiciona novas capacidades algorítmicas.

Conclusão

- **Eficácia do Algoritmo:** O algoritmo Successive Shortest Path (SSP) resolve exatamente o MCF na instância de rede hídrica do DF, fornecendo a distribuição de custos mínimos.
- **Perspectiva de Futuro:** O framework de pontes de Schrödinger atua como a generalização natural do nosso modelo determinístico para tratar incertezas dinâmicas reais.

Referências I



Ravindra K. Ahuja, Thomas L. Magnanti, and James B. Orlin.
Network Flows: Theory, Algorithms, and Applications.
Prentice Hall, 1993.



Thomas H. Cormen, Charles E. Leiserson, Ronald L. Rivest,
and Clifford Stein.
Introduction to Algorithms.
MIT Press, 3rd edition, 2009.

Referências II



Marco Cuturi.

Sinkhorn distances: Lightspeed computation of optimal transport.

Advances in Neural Information Processing Systems (NeurIPS),
26:2292–2300, 2013.



Leonid V. Kantorovich.

On the translocation of masses.

Doklady Akademii Nauk USSR, 37:199–201, 1942.



UnB

Referências III



Michele Mascherpa, Isabel Haasler, Bengt Ahlgren, and Johan Karlsson.

Estimating pollution spread in water networks as a Schrödinger bridge problem with partial information.

European Journal of Control, 74:100846, 2023.



Michele Mascherpa, Victor Molnő, Carsten Skovmose Kallesøe, and Johan Karlsson.

A proximal approach to the Schrödinger bridge problem with incomplete information and application to contamination tracking in water networks.

arXiv preprint arXiv:2604.06078, 2026.



Referências IV



Gabriel Peyré and Marco Cuturi.

Computational optimal transport.

Foundations and Trends in Machine Learning,
11(5-6):355–607, 2019.



Yossi Rubner, Carlo Tomasi, and Leonidas J. Guibas.

The Earth Mover's Distance as a Metric for Image Retrieval.

International Journal of Computer Vision, 40(2):99–121, 2000.

Obrigado!

Perguntas?



Repositório do Projeto

